

Documento de trabajo del grupo

Laboratorio 4 — Análisis de datos geoespaciales
Monitoreo de cianobacteria en los lagos de Atitlán y Amatitlán

Para qué sirve este documento

Registra **cómo** se hizo el laboratorio: las decisiones que se tomaron, por qué se tomaron, qué se probó y descartó, y en qué orden se avanzó. El informe entregado por separado contiene los **resultados**; este contiene el **proceso**. El historial de cambios verificable está en el repositorio de código, cuyo registro completo se reproduce en la sección 5.

Pablo Cabrera · Luis Mendoza

CC3084 — Data Science · Universidad del Valle de Guatemala · Semestre II 2026
16 de agosto de 2026

Repositorio: <https://github.com/pablouwunya2021/lab4ds>

1. Cómo se abordó el laboratorio

El enunciado pedía descargar imágenes de Sentinel-2 para dos lagos en once fechas cada uno, aplicarles el script de detección de cianobacteria de Sentinel Hub junto con el NDVI y el NDWI, y a partir de ahí hacer un análisis temporal, uno espacial, uno de correlación y una comparación entre ambos lagos.

La decisión estructural del trabajo fue **hacer el cálculo de los índices en la nube y descargar solo el resultado**, en lugar de bajar las escenas completas y procesarlas localmente. Cada petición al API devuelve un archivo de ocho capas ya calculadas (clorofila-a, NDCI, NDVI, NDWI, índice de algas flotantes, máscara de agua, probabilidad de nube y máscara de datos válidos). Esto reduce la descarga a lo estrictamente necesario, que es lo que pedía el enunciado, y garantiza que el índice se calcule exactamente con el script publicado y no con una reimplementación propia.

La segunda decisión fue **separar el cálculo de la interpretación**. Los módulos de análisis producen las cifras y además redactan los hallazgos a partir de esas mismas cifras; el informe se arma leyendo ese resultado. Así ninguna cifra del informe está escrita a mano, y si se añade una fecha nueva todo el documento se regenera coherente.

Estructura del código

Módulo	Responsabilidad
config.py	Áreas de interés, fechas oficiales, credenciales y conexión al API
evalscripts.py	Los scripts de Sentinel Hub: cianobacteria, NDVI, NDWI y color real
descarga.py	Ejercicios 1–3: peticiones al API y guardado de los GeoTIFF
carga.py	Limpieza: máscara de agua, filtro de nubes y dominio espacial común
temporal.py	Ejercicio 4: serie por fecha, picos y estacionalidad
espacial.py	Ejercicio 5: mapas por fecha, comparativos, persistencia e interactivos
correlacion.py	Ejercicio 6: relación de NDVI y NDWI con la cianobacteria
comparacion.py	Ejercicio 7: intensidad, frecuencia y causas por lago
exploratorio.py	Ejercicio 8: distribuciones, percentiles y extensión afectada
analisis.py	Orquestador: corre los ejercicios 4 a 8 y vuelca los resultados
informe.py	Genera el informe final en PDF

2. Decisiones de método y por qué se tomaron

Esta sección es el núcleo del documento. Cada entrada describe una decisión que cambió los resultados, qué evidencia la motivó y cómo se resolvió. Todas surgieron de revisar resultados intermedios que no cuadraban, no de planificación previa.

2.1 Usar Sentinel-2 L1C y no L2A

Situación. El script de cianobacteria de CyanoLakes está publicado y calibrado para L1C (reflectancia en el tope de la atmósfera). La primera versión del trabajo usó L2A (reflectancia de superficie) por ser el nivel habitual en estudios de calidad de agua.

Qué se observó. Al validar la máscara de agua sobre Amatitlán (2026-02-07) se vio que con L2A el script reconocía como agua 3.6 km² de los 14.8 km² del lago, es decir el 26 %. La corrección atmosférica deja el agua tan oscura que los umbrales internos del script (MNDWI > 0.42 y DBSI) dejan de cumplirse. Con L1C reconoce 14.6 km², el 99 %.

Resolución. Se cambió toda la descarga a L1C. Como L1C no trae la capa de clasificación de escena, el filtro de nubes pasó a hacerse con la probabilidad de nube de s2cloudless, descartando por encima del 40 %.

2.2 Recortar a cero los valores negativos de clorofila-a

Situación. El polinomio del script devuelve concentraciones negativas cuando el NDCI es negativo, que es lo que ocurre en agua muy limpia. La primera versión los trataba como dato inválido y los descartaba.

Qué se observó. Ese descarte eliminaba el 38 % de la superficie de Atitlán en su fecha más limpia, y lo hacía únicamente por el extremo bajo de la distribución. El efecto era un sesgo sistemático al alza, concentrado justo en el lago y las fechas más limpias, que es donde el sesgo cambia las conclusiones.

Resolución. Los negativos se recortan a cero, que es su lectura física: clorofila por debajo del límite de detección. La cobertura de Atitlán pasó de 62 % a 100 % y su mediana del 2025-01-18 bajó de 0.81 a 0.33 µg/L.

2.3 Fijar un dominio espacial común a todas las fechas

Situación. Cada fecha detecta su propio contorno de agua, que varía con el nivel del lago, la nubosidad y las condiciones de la superficie.

Qué se observó. Si cada fecha se analizara sobre los píxeles que ella misma detecta como agua, los promedios compararían superficies distintas y los mapas de diferencia entre fechas no tendrían sentido: una variación del contorno se leería como un cambio en la floración.

Resolución. Se define el espejo de agua estable como los píxeles clasificados como agua en al menos la mitad de las fechas, y todas las fechas del lago se analizan sobre ese mismo conjunto.

2.4 Medir la persistencia de forma relativa y no absoluta

Situación. La primera versión medía las zonas persistentes de acumulación como los píxeles que superan los 10 µg/L en la mitad o más de las fechas.

Qué se observó. Esa definición daba 0 % en ambos lagos, es decir, no respondía la pregunta. Un umbral absoluto no sirve para esto: en un lago limpio no lo alcanza nunca nadie y en uno cargado lo alcanzan casi todos; en ambos casos el resultado es igual de poco informativo.

Resolución. Se mide en relación a cada fecha: se marca el quinto más afectado del lago ese día y se cuenta en cuántas fechas cada punto cae dentro de él. Con esa definición, el 8.1 % de la superficie de Atitlán y el 4.4 % de la de Amatitlán aparecen ahí en la mitad o más de las fechas, lo que sí revela una geografía estable del problema.

2.5 Escala de color propia para cada lago

Situación. Lo natural para comparar es usar una única escala de color en todos los mapas.

Qué se observó. Atitlán se mueve entre 0 y 2 µg/L y Amatitlán llega a decenas. Con una escala común, todos los mapas de Atitlán salían en blanco y su estructura interna era invisible, que es justo lo que el ejercicio 5 pide analizar.

Resolución. Cada lago usa su propia escala, común a todas sus fechas para que las fechas sigan siendo comparables entre sí. El informe advierte de forma explícita que un tono oscuro en un lago no equivale al mismo tono en el otro, y la comparación entre lagos se hace con cifras.

2.6 Reportar la tendencia de Amatitlán con salvedad

Situación. El ajuste lineal sobre las once fechas de Amatitlán da una pendiente de +3.1 µg/L por año.

Qué se observó. De las once fechas de ese lago, solo una cae en época lluviosa, y es la última de la serie. Es también la fecha con el valor más alto. Con ese reparto, la tendencia temporal y el efecto estacional son matemáticamente indistinguibles.

Resolución. La cifra se reporta, pero acompañada siempre de la advertencia de que no puede leerse como un empeoramiento real del lago. Lo mismo se aplica a todo el análisis estacional.

3. Resumen de resultados obtenidos

Los resultados completos, con sus mapas y gráficos, están en el informe entregado por separado. Aquí se recogen solo las cifras de referencia.

Indicador	Atitlán	Amatitlán
Clorofila-a promedio del período	1.2 µg/L	6.4 µg/L
Valor más alto de una fecha	2.1 µg/L	11.6 µg/L
Fechas con floración (promedio > 10 µg/L)	0 de 11	2 de 11
Superficie afectada en la peor fecha	0.2 %	54 %
Superficie con acumulación persistente	8.1 %	4.4 %
Coefficiente de variación entre fechas	0.40	0.37
Espejo de agua analizado	122.1 km ²	14.6 km ²

La diferencia entre ambos lagos se contrastó con una prueba de Mann-Whitney (no paramétrica, adecuada para once observaciones por grupo sin garantía de normalidad): $U = 0$, $p = 0.0001$. La mediana de Amatitlán es 4.6 veces la de Atitlán.

El hallazgo más relevante

El 19 de junio de 2026, el 54 % de la superficie de Amatitlán superó el umbral de floración, con un promedio de 11.6 µg/L. Es un episodio visible a simple vista en la imagen en color real, lo que sirve como validación cualitativa de que el índice está detectando algo físicamente presente y no un artefacto del procesamiento.

4. Reparto del trabajo

Completar antes de entregar

Esta tabla está en blanco a propósito: el reparto real lo conoce el grupo. La rúbrica evalúa a cada integrante según sus contribuciones, así que conviene llenarla con precisión y que coincida con lo que muestra el historial de commits del repositorio.

Tarea	Responsable	Observaciones
Configuración del acceso al API y credenciales		
Evalscripts y descarga de los rásters (Ej. 1–3)		
Limpieza y validación de los datos		
Análisis temporal (Ej. 4)		
Análisis espacial y mapas (Ej. 5)		
Correlación de índices (Ej. 6)		
Comparación entre lagos (Ej. 7)		
Análisis exploratorio adicional (Ej. 8)		
Redacción del informe		
Revisión y control de versiones		

5. Historial de cambios

El historial verificable y con el detalle completo de cada cambio está en el repositorio: <https://github.com/pablouwunya2021/lab4ds>. Cada commit incluye en su mensaje la justificación de la decisión tomada y, cuando corresponde, las cifras que la motivaron. A continuación, el registro resumido.

Versión	Fecha	Cambio
30f26b6	16/08/2026 16:29	Ej. 1: estructura del proyecto y conexión al API de Sentinel Hub
36ea4bd	16/08/2026 16:35	Ej. 4-8: módulos de análisis temporal, espacial, correlación y comparación
691048e	16/08/2026 16:54	Ej. 2-3: corregir la colección a L1C y fijar el dominio espacial
e07f238	16/08/2026 16:56	Ej. 3 y 5: añadir la vista original del script de CyanoLakes
88ac142	16/08/2026 16:58	Corregir sesgo al tratar los valores negativos de clorofila-a
052c7ac	16/08/2026 17:09	Ej. 4-8: resultados finales, correcciones de método y acabado del informe

Cómo reproducir el trabajo

Cualquier persona con una cuenta gratuita del Copernicus Data Space Ecosystem puede regenerar el laboratorio completo desde cero con tres órdenes, tras copiar el archivo `.env.example` a `.env` y rellenarlo con sus credenciales:

```
> python -m src.descarga # descarga las 22 imágenes
> python -m src.analisis # figuras, mapas y tablas
> python -m src.informe # informe final en PDF
```

Las credenciales nunca se versionan: el archivo `.env` está excluido del repositorio y se comprobó explícitamente que no se subió.

6. Estado de los entregables

Entregable	Estado	Detalle
Informe en PDF con resultados y explicaciones	Entregado	Informe_Lab4_Cianobacteria_Atitalan_Amatitlan.pdf, 24 páginas, dirigido a lectores sin conocimientos de programación
Script de Python usado para el análisis	Entregado	11 módulos en src/, documentados y reproducibles
Link del repositorio usado para versionar	Entregado	https://github.com/pablouwunya2021/lab4ds
Link del documento de trabajo del grupo	Por completar	Este documento es su contenido; falta subirlo a un documento compartido y completar el reparto de la sección 4

7. Qué se dejó fuera y por qué

- **Validación con muestras de campo.** No se dispuso de mediciones de laboratorio simultáneas a las fechas de las imágenes, así que los valores absolutos de clorofila-a no pudieron contrastarse. La validación fue cualitativa: comprobar que lo que el índice marca como floración se ve en la imagen en color real.
- **Variables ambientales complementarias.** Temperatura del agua, nutrientes y caudal de los afluentes habrían permitido explicar las causas de cada episodio, pero quedan fuera de lo que ofrece Sentinel-2.
- **Serie temporal más larga.** El enunciado fijó once fechas por lago. Es suficiente para describir el comportamiento general, pero corto para afirmar tendencias de largo plazo o estacionalidad con seguridad estadística, cosa que el informe señala explícitamente en vez de dar por buenas las pendientes calculadas.
- **Otros índices de calidad de agua.** Se consideró añadir el índice de sólidos suspendidos y el de turbidez para separar mejor la biomasa de los sedimentos, pero el enunciado acotaba el trabajo al índice de cianobacteria más NDVI y NDWI, y se respetó ese alcance.