

Laboratorio 4 · Parte 2
**Clasificación geoespacial de alta presencia de
cianobacteria**

Pablo Cabrera · Luis Mendoza
CC3084 Data Science · UVG · Semestre II 2026
2026-08-20

Objetivos y alcance

Se desarrollan tres clasificadores y se contrastan evaluaciones aleatoria, espacial, temporal y entre lagos. La respuesta es una categoría operativa derivada de un proxy satelital; no mide toxicidad ni sustituye muestreo de campo.

Preparación y limpieza

Cada fila conserva lago, fecha, celda raster, coordenadas WGS84/UTM 15N y metadatos. Todos los descartes se registran; no se eliminan observaciones silenciosamente.

Linaje de la respuesta

$NDCI = (B05 - B04) / (B05 + B04)$; clorofila-a proxy = $826.57 \cdot NDCI^3 - 176.43 \cdot NDCI^2 + 19 \cdot NDCI + 4.071$; categoría alta = 1 si proxy $\geq 10 \mu\text{g/L}$. El corte no equivale a concentración de cianobacterias ni riesgo toxicológico confirmado.

Auditoría de predictores

variable	permitido_modelo_principal	razon
chl	False	transformación directa de NDCI y fuente de y
ndci	False	fuente directa del proxy continuo
alta_presencia	False	variable respuesta
B04	False	componente directo de NDCI; también de NDVI y FAI
B05	False	componente directo de NDCI
ndvi	False	comparte B04 con NDCI; exclusión conservadora
fai	False	comparte B04 con NDCI; exclusión conservadora
lon/lat/x_utm/y_utm	False	puede memorizar lago o zonas; solo agrupación/mapas
lake	False	identifica dominio; solo segmentación y experimentos
B02	True	no participa directamente en NDCI según el linaje declarado
B03	True	no participa directamente en NDCI según el linaje declarado
B07	True	no participa directamente en NDCI según el linaje declarado
B08	True	no participa directamente en NDCI según el linaje declarado
B8A	True	no participa directamente en NDCI según el linaje declarado
B11	True	no participa directamente en NDCI según el linaje declarado
B12	True	no participa directamente en NDCI según el linaje declarado
ndwi	True	no participa directamente en NDCI según el linaje declarado
doy_sin	True	no participa directamente en NDCI según el linaje declarado
doy_cos	True	no participa directamente en NDCI según el linaje declarado
rainy_season	True	no participa directamente en NDCI según el linaje declarado

Bitácora de filtros




lake	date	filter	before	after	removed
Atitlan	2025-01-18	inside_aoi	1194375	1179533	14842
Atitlan	2025-01-18	datamask	1179533	1179533	0
Atitlan	2025-01-18	water	1179533	308960	870573
Atitlan	2025-01-18	cloud	308960	308960	0
Atitlan	2025-01-18	finite	308960	308960	0
Atitlan	2025-01-18	physical_range	308960	192469	116491
Atitlan	2025-01-18	duplicates	192469	192469	0
Atitlan	2025-04-13	inside_aoi	1194375	1179533	14842
Atitlan	2025-04-13	datamask	1179533	1179533	0
Atitlan	2025-04-13	water	1179533	305329	874204
Atitlan	2025-04-13	cloud	305329	305267	62
Atitlan	2025-04-13	finite	305267	305267	0
Atitlan	2025-04-13	physical_range	305267	303283	1984
Atitlan	2025-04-13	duplicates	303283	303283	0
Atitlan	2025-05-13	inside_aoi	1194375	1179533	14842
Atitlan	2025-05-13	datamask	1179533	1179533	0
Atitlan	2025-05-13	water	1179533	305290	874243
Atitlan	2025-05-13	cloud	305290	305276	14
Atitlan	2025-05-13	finite	305276	305276	0
Atitlan	2025-05-13	physical_range	305276	269498	35778
Atitlan	2025-05-13	duplicates	269498	269498	0
Atitlan	2025-07-17	inside_aoi	1194375	1179533	14842
Atitlan	2025-07-17	datamask	1179533	1179533	0
Atitlan	2025-07-17	water	1179533	291659	887874
Atitlan	2025-07-17	cloud	291659	291259	400
Atitlan	2025-07-17	finite	291259	291259	0
Atitlan	2025-07-17	physical_range	291259	238277	52982
Atitlan	2025-07-17	duplicates	238277	238277	0
Atitlan	2025-11-21	inside_aoi	1194375	1179533	14842
Atitlan	2025-11-21	datamask	1179533	1179533	0

Evaluación 70/30



model	accuracy	balanced_accuracy	precision	recall	f1	roc_auc	pr_auc
logistic_regression	0.9884	0.9916	0.546	0.9949	0.7051	0.9988	0.9234
random_forest	0.9975	0.9423	0.9341	0.8854	0.9091	0.9985	0.9726
hist_gradient_boosting	0.9975	0.9541	0.9119	0.9094	0.9106	0.9988	0.9719

Validaciones espacial, temporal y entre lagos


strategy	fold	model	balanced_accuracy	precision	recall	f1	pr_auc
spatial	1	logistic_regression	0.9864	0.4348	0.991	0.6044	0.9302
spatial	1	random_forest	0.9145	0.9592	0.8295	0.8896	0.9721
spatial	1	hist_gradient_boosting	0.9191	0.948	0.8388	0.8901	0.9709
spatial	2	logistic_regression	0.9909	0.5343	0.9939	0.695	0.874
spatial	2	random_forest	0.9098	0.9109	0.8206	0.8634	0.946
spatial	2	hist_gradient_boosting	0.9236	0.8773	0.8488	0.8629	0.9387
spatial	3	logistic_regression	0.9933	0.6042	0.996	0.7522	0.9656
spatial	3	random_forest	0.9547	0.9197	0.9105	0.9151	0.9733
spatial	3	hist_gradient_boosting	0.9552	0.9089	0.9118	0.9103	0.9655
spatial	4	logistic_regression	0.9901	0.529	0.9926	0.6902	0.8881
spatial	4	random_forest	0.9398	0.9166	0.8808	0.8983	0.9695
spatial	4	hist_gradient_boosting	0.951	0.8892	0.9036	0.8964	0.9619
spatial	5	logistic_regression	0.9935	0.6944	0.993	0.8173	0.9378
spatial	5	random_forest	0.9378	0.9517	0.8762	0.9124	0.9729
spatial	5	hist_gradient_boosting	0.954	0.9363	0.9089	0.9224	0.976
temporal	1	logistic_regression	0.9853	0.6545	0.9997	0.7911	0.9407
temporal	1	random_forest	0.5279	0.966	0.056	0.1058	0.9419
temporal	1	hist_gradient_boosting	0.8483	0.6818	0.715	0.698	0.6384
cross_lake_Atitlan_to_Amatitlan	1	logistic_regression	0.648	0.6202	0.3195	0.4218	0.469
cross_lake_Atitlan_to_Amatitlan	1	random_forest	0.5001	0.75	0.0002	0.0004	0.5183
cross_lake_Atitlan_to_Amatitlan	1	hist_gradient_boosting	0.5034	0.1462	0.0228	0.0394	0.0972
cross_lake_Amatitlan_to_Atitlan	1	logistic_regression	0.9375	0.1516	0.8774	0.2585	0.6932
cross_lake_Amatitlan_to_Atitlan	1	random_forest	0.7032	0.4836	0.4066	0.4417	0.4058
cross_lake_Amatitlan_to_Atitlan	1	hist_gradient_boosting	0.8996	0.4606	0.7997	0.5845	0.6088




Matrices de confusión sobre el test común 30%.



Bloques espaciales regulares de 1 km.




Importancia por permutación sobre test.





SHAP de la clase positiva; asociación, no causalidad.

Amatitlan · 2026-06-19 · probabilidad de alta presencia




Mapa predictivo de Amatitlán.

Atitlan · 2026-07-22 · probabilidad de alta presencia




Mapa predictivo de Atitlán.

Amatitlan · 2026-06-19 · errores a umbral 0.50



Errores espaciales de Amatitlán.

Atitlan · 2026-07-22 · errores a umbral 0.50



Errores espaciales de Atitlán.

Modelos e hiperparámetros

Regresión logística, Random Forest e HistGradientBoosting se implementan en pipelines. La búsqueda usa solo entrenamiento, PR-AUC como criterio y un test 30% común que no participa en decisiones.

Criterio ambiental

La regla previa exige precisión mínima 0.80 y, entre modelos elegibles, prioriza PR-AUC y recall. Ganó random_forest: PR-AUC=0.973, precisión=0.934, recall=0.885. Los falsos negativos pueden retrasar verificación de campo; los falsos positivos consumen recursos operativos.

Comparación de validaciones

El ganador obtuvo recall temporal=0.056, frente a 0.885 en la división aleatoria. Esta caída evidencia dependencia temporal. En transferencia entre lagos sus recalls fueron Atitlan_to_Amatitlan: 0.000, Amatitlan_to_Atitalan: 0.407.

Limitaciones

Once fechas por lago, autocorrelación, dominio espectral distinto, nubes y una respuesta construida del mismo sensor limitan inferencia y generalización. Importancia no implica causalidad. Se requiere validación in situ de clorofila, composición taxonómica y toxinas.

Referencias

Mishra & Mishra (2012), DOI 10.1016/j.rse.2011.10.016. WHO (2021), Guidelines on recreational water quality, ISBN 9789240031302. US EPA (2019), Recommendations for Cyanobacteria and Cyanotoxin Monitoring in Recreational Waters. Kravitz & Matthews (2020), CyanoLakes custom script.

Reproducibilidad

Comandos: python -m src.descarga --ml; python -m src.parte2; pytest -q; jupyter nbconvert --execute --to notebook --inplace notebooks/laboratorio4_parte2.ipynb; python -m src.informe_parte2.